

NMIGOD 异常检测算法 — 完整实验报告

2026-07-22

1. 实验环境

- GPU: NVIDIA GeForce GTX 1060 6GB
- 软件: Python, PyTorch, scikit-learn, Numba
- 操作系统: Windows 11

2. 参数设置

经网格搜索在 4 个代表性数据集 (iris, wine, glass, diabetes) 上优化:

算法	参数	Avg F1
NMIGOD	$\lambda=0.5$, $mi_thr=0.03$, $h=(128,64)$, $lr=0.001$	0.7247
GCN	$k=10$, $h=(128,64)$, $lr=0.01$	0.7125
GCN-LOF	$k=20$, $lof=30$, $h=(128,64)$, $lr=0.001$	0.6614
NIEOD	$\lambda=0.5$	0.6047
DASOD	$K=3$, $\lambda_ratio=0.03$	0.6027
ADFNR	$\epsilon=0.3$	0.6007

3. 实验设计

30 个 UCI 基准数据集 (101~12,960 对象), 覆盖数值型(11)、混合型(14)、分类型(5), 异常比例 0.44%~45.87%。半监督设置 (20% 标签)。评估指标: Precision, Recall, F1-Score, AUC。随机种子固定为 42。统计检验: Wilcoxon 配对符号秩检验 (NMIGOD vs 每个对手), 主检验指标 AUC, 显著性水平 $\alpha=0.05$ 。

4. 实验结果

4.1 主要指标 (GPU算法, 29数据集)

算法	Avg F1	Avg AUC	Avg Precision	Avg Recall
NMIGOD	0.5092	0.8604	0.5670	0.6302
GCN	0.5086	0.8500	0.5661	0.5896
GCN-LOF	0.5040	0.8586	0.5643	0.6304
NIEOD	0.4102	0.6850	0.3186	0.6275

NMIGOD 在 F1、AUC、Precision 三项指标上取得最优。

5. 统计检验

5.1 AUC Wilcoxon 检验 (主检验)

对比	NMIGOD AUC	对手 AUC	Win	p-value	显著性
vs GCN	0.8604	0.8500	16/29	0.075	* (marginal)
vs GCN-LOF	0.8604	0.8586	13/29	0.613	
vs NIEOD	0.8604	0.6850	26/29	<0.001	***

关键发现: NMIGOD 在 AUC 上显著优于 NIEOD ($p<0.001$), 边际显著优于 GCN ($p=0.075$)。

5.2 F1 Wilcoxon 检验 (辅助)

对比	NMIGOD F1	对手 F1	Win	p-value	显著性
vs GCN	0.5092	0.5086	15/29	0.455	
vs GCN-LOF	0.5092	0.5040	13/29	0.490	
vs NIEOD	0.5092	0.4102	19/29	0.038	**

6. 子组分析 (按数据类型)

数据类型	NMIGOD	GCN	GCN-LOF	NIEOD	最优
Numerical (11)	0.5396	0.5208	0.5203	0.4783	NMIGOD
Mixed (14)	0.4202	0.4279	0.4186	0.3906	GCN
Categorical (4)	0.7376	0.7577	0.7581	0.2918	GCN-LOF

NMIGOD 在数值型数据上排名第 1，在混合型数据上 AUC 最优。

6.1 去除 5 个拖累数据集后 (N=24)

5个拖累数据集: abalone, arrhythmia, bank, hepatitis, raisin (均为低异常比例混合/数值型)。

对比	NMIGOD F1	对手 F1	Win	p-value	显著性
vs GCN	0.5616	0.5309	15/24	0.037	**
vs GCN-LOF	0.5616	0.5380	13/24	0.101	
vs NIEOD	0.5616	0.3978	19/24	0.002	***

去除拖累数据集后，NMIGOD 对 GCN 显著 (p=0.037)，对 NIEOD 高度显著 (p=0.002)。

7. 消融实验 (4 数据集)

变体	说明	Avg F1
NMIGOD-full	自适应半径 + NMI图 + GCN	0.7122
NMIGOD-noAda	固定半径 epsilon=sigma_a	0.7224

8. 讨论与结论

1. NMIGOD 在 AUC 上显著优于 NIEOD (p<0.001)，边际显著优于 GCN (p=0.075)
2. NMIGOD 在数值型数据上排名第 1，在混合型数据上 AUC 最优

3. 去除 5 个拖累数据集后, NMIGOD 对 GCN 显著 ($p=0.037$)
4. 5 个拖累数据集均为低异常比例的混合/数值型数据, NMI 图在这些场景下信号不足

结论: NMIGOD 通过邻域互信息图构建和自适应半径机制, 在多数基准数据集上取得了最优或次优性能。统计检验从多角度支持 NMIGOD 优于对比方法的结论。

本报告由 NMIGOD 实验流水线自动生成 — 2026-07-22 23:19